

Walk Attention: Álgebras de Caminos de Quivers como una Atención Dispersa Multi-Salto para Mitigar el Over-Squashing en GNNs

Carlos Isaac Zainea Maya¹[0000-0002-6459-2397] and Agustín Moreno
Cañadas¹[0000-0001-6812-5131]

Universidad Nacional de Colombia, Departamento de Matemáticas,
Bogotá, Colombia
{cizaineam, amorenoca}@unal.edu.co

Resumen Las redes neuronales de grafos (GNN) de paso de mensajes sufren de *over-squashing*: cuando la información debe viajar por muchos caminos largos hacia un nodo, se comprime en un vector de ancho fijo y la señal se pierde. Introducimos **Walk Attention**, una arquitectura que aborda el over-squashing a través del *álgebra de caminos* $\mathbb{k}Q$ del grafo dirigido (quiver) subyacente a los datos. Las componentes graduadas de $\mathbb{k}Q$ cuentan los caminos dirigidos de una longitud dada entre dos vértices, dando una descripción exacta y algebraica de la alcanzabilidad multi-salto. Usamos esta estructura para definir una atención dispersa y multi-salto: un nodo atiende directamente a todo vértice alcanzable por un camino de longitud g , donde el álgebra provee el *soporte* de la atención y la red aprende los *pesos*. Damos una construcción autocontenida de los quivers, sus álgebras de caminos y los operadores de walk, relacionándolos con el paso de mensajes y la atención de los Transformers. En una familia controlada de cuellos de botella con over-squashing ajustable, Walk Attention alcanza $1,000 \pm 0,000$ de precisión sobre cinco semillas donde una atención de grafos de un salto colapsa al azar (0,26–0,44) y un agregador multi-salto de pesos fijos llega solo a 0,50–0,62; en la prueba estándar RINGTRANSFER se mantiene exacta (1,00) mientras las líneas base de un salto se desmoronan, y en el benchmark real Peptides-func es competitiva con líneas base fuertes. Su ventaja es por tanto dependiente del régimen: decisiva cuando el over-squashing es severo, un empate cuando es leve. Además, reportamos un resultado negativo que motiva el diseño: usar el *cociente* del álgebra para *colapsar* caminos equivalentes descarta la multiplicidad que la tarea necesita y falla. El álgebra de caminos es valiosa no como un cociente que comprime información, sino como el objeto que *define el soporte de la atención*.

Keywords: Redes neuronales de grafos · Over-squashing · Álgebra de caminos · Quiver · Atención · Paso de mensajes.

1. Introducción

Las redes neuronales de grafos (GNN) construidas sobre el paradigma de paso de mensajes [5] actualizan cada nodo agregando mensajes de sus vecinos inmediatos e iterando esta regla local a través de las capas. Tras k capas, la información de nodos a k saltos de distancia alcanza un nodo objetivo. Aunque simple y efectivo, este esquema tiene un modo de fallo bien documentado: el *over-squashing* [1]. Cuando el número de caminos que canalizan información hacia un nodo crece—típicamente de forma exponencial con la distancia—los mensajes que llevan todos esos caminos deben comprimirse en un único vector de ancho fijo. El receptor no puede separarlos, y la señal de largo alcance se pierde. El over-squashing es el obstáculo principal para aprender tareas cuyas etiquetas dependen de información distante o distribuida globalmente.

Los remedios existentes actúan sobre el grafo o sobre la agregación: el *rewiring* añade o repondera aristas para ensanchar los cuellos de botella [9], el *coarsening* y el *pooling* de grafos reducen el grafo intentando preservar su estructura, y los análisis basados en curvatura explican *dónde* ocurre el squashing [3]. Una línea de trabajo complementaria reemplaza la agregación local por *atención* global como en los Transformers [10], al costo de una interacción de todos-contra-todos que ignora la estructura del grafo.

En este artículo tomamos una ruta diferente, fundamentada en la teoría de representaciones de quivers. Un *quiver* es un grafo dirigido, posiblemente con flechas múltiples [8,2], y su *álgebra de caminos* $\mathbb{k}Q$ tiene como base los caminos dirigidos del quiver, con la concatenación como multiplicación. La pieza graduada $e_i \cdot \mathbb{k}Q_g \cdot e_j$ de esta álgebra tiene como base los caminos dirigidos de longitud g del vértice i al vértice j ; su dimensión es igual a $(A^g)_{ij}$, la entrada correspondiente de la g -ésima potencia de la matriz de adyacencia. El álgebra de caminos provee, por tanto, una *descripción exacta y algebraica de la alcanzabilidad y la multiplicidad multi-salto*.

Nuestra observación central es que esta estructura algebraica es precisamente lo que se necesita para definir una atención dispersa y multi-salto con fundamento. Dejamos que cada nodo atienda directamente a todo vértice alcanzable desde él por un camino de longitud g : el álgebra de caminos provee el *soporte* de la atención (qué pares pueden interactuar a rango g), y la red aprende los *pesos* (cuánto). Dado que el soporte de alcanzabilidad por walks es disperso—típicamente una pequeña fracción de todos los pares de nodos—esto es mucho más barato que la auto-atención completa, sin dejar de actuar a distancia y así evitando el cuello de botella iterativo que causa el over-squashing. Llamamos a la arquitectura resultante **Walk Attention**.

Contribuciones.

1. Damos una construcción *autocontenida* (Sección 3) de los quivers, las álgebras de caminos, las componentes graduadas y los *operadores de walk* asociados, dirigida a una audiencia de reconocimiento de patrones e independiente de cualquier exposición previa a la teoría de representaciones.

2. Definimos **Walk Attention** (Sección 4): una atención multi-salto aprendida cuyo soporte es la estructura de alcanzabilidad por walks del álgebra de caminos, y la relacionamos con el paso de mensajes y con la atención de los Transformers.
3. En una familia controlada de cuellos de botella con over-squashing ajustable (Sección 5), Walk Attention alcanza una precisión de $1,000 \pm 0,000$ sobre cinco semillas donde la atención de grafos de un salto colapsa al azar y un agregador multi-salto de pesos fijos solo tiene éxito parcial; en el benchmark real Peptides-func es competitiva con líneas base fuertes, por lo que su ventaja es dependiente del régimen (decisiva bajo over-squashing severo, un empate cuando es leve).
4. Reportamos un resultado *negativo* que afina el diseño: colapsar caminos equivalentes mediante el *cociente* del álgebra de caminos descarta la multiplicidad necesaria y falla. El papel del cociente es *moldear* el soporte, no comprimir la señal.

2. Trabajo Relacionado

Over-squashing. Alon y Yahav [1] identificaron el over-squashing y propusieron la prueba NEIGHBORSMATCH, en la que las GNN estándar se degradan abruptamente con el radio del problema. Topping et al. [9] conectaron el over-squashing con la curvatura negativa del grafo y propusieron el rewiring por flujo de Ricci discreto estocástico (SDRF); Di Giovanni et al. [3] dieron un análisis de sensibilidad que relaciona el squashing con el ancho, la profundidad y la topología. Estos trabajos o bien modifican el grafo o bien caracterizan el fenómeno. Nosotros, en cambio, cambiamos el operador de agregación, atendiendo a distancia sobre un soporte definido algebraicamente.

Atención y graph Transformers. Las redes de atención de grafos [11] aprenden pesos de atención de un salto; los graph Transformers completos aplican la auto-atención de los Transformers [10] sobre todos los pares de nodos, recuperando el largo alcance a costo cuadrático y con codificaciones posicionales/estructurales para reinyectar la topología. Walk Attention se sitúa entre ambos: es atención, pero su soporte es la alcanzabilidad dispersa multi-salto por walks del quiver, en lugar de un salto o de todos los pares.

Estructura de caminos y walks. El conteo de caminos y las potencias de la matriz de adyacencia son clásicos, y el álgebra de caminos de un quiver es estándar en la teoría de representaciones [8,2]. Las álgebras de configuración de Brauer y construcciones afines se han aplicado recientemente a problemas combinatorios y aplicados por Moreno Cañadas y colaboradores [7,6]. Hasta donde sabemos, usar el álgebra de caminos graduada para definir el *soporte* de una atención de grafos multi-salto aprendida es nuevo.

3. El álgebra de caminos de un quiver

Esta sección es autocontenida. Construimos, desde los primeros principios, los objetos algebraicos en los que se apoya el modelo de la Sección 4: quivers, caminos, el álgebra de caminos, su graduación por longitud, y los *operadores de recorrido* que codifican la alcanzabilidad a múltiples saltos. No se asume ningún conocimiento previo de teoría de representaciones; las referencias estándar son [8,2].

3.1. Quivers y caminos

Definition 1 (Quiver). *Un quiver es una cuádrupla $Q = (Q_0, Q_1, s, t)$ donde Q_0 es un conjunto finito de vértices, Q_1 es un conjunto finito de flechas, y $s, t: Q_1 \rightarrow Q_0$ asignan a cada flecha α su fuente $s(\alpha)$ y su objetivo $t(\alpha)$. Escribimos $\alpha: i \rightarrow j$ cuando $s(\alpha) = i$ y $t(\alpha) = j$.*

Un quiver es, por tanto, un grafo dirigido en el que se permiten múltiples flechas entre el mismo par ordenado de vértices (un *multigrafo*). Para el reconocimiento de patrones esto es exactamente el dato de una estructura relacional dirigida: los vértices son entidades y las flechas son relaciones dirigidas, con las flechas paralelas registrando la multiplicidad. Escribimos $n = |Q_0|$ e identificamos Q_0 con $\{1, \dots, n\}$.

Definition 2 (Camino). *Un camino de longitud $g \geq 1$ en Q es una sucesión de flechas $p = \alpha_g \cdots \alpha_2 \alpha_1$ tal que $t(\alpha_r) = s(\alpha_{r+1})$ para $1 \leq r < g$; es decir, las flechas se componen cabeza con cola. Su fuente es $s(p) = s(\alpha_1)$ y su objetivo es $t(p) = t(\alpha_g)$. Para cada vértice i admitimos además un camino trivial e_i de longitud 0 con $s(e_i) = t(e_i) = i$.*

Leemos los caminos de derecha a izquierda, como en la composición de funciones. Un camino es un *recorrido* dirigido: los vértices y las flechas pueden repetirse. El número de recorridos distintos de una longitud dada entre dos vértices es la cantidad que impulsa el over-squashing, y el álgebra de caminos lo hace algebraicamente explícito.

3.2. El álgebra de caminos y su graduación

Sea $\mathbb{k}$ un cuerpo (en la práctica $\mathbb{k} = \mathbb{R}$).

Definition 3 (Álgebra de caminos). *El álgebra de caminos $\mathbb{k}Q$ es el $\mathbb{k}$ -espacio vectorial con base el conjunto de todos los caminos de Q (incluidos los caminos triviales e_i), dotado de la multiplicación bilineal dada sobre los caminos base por concatenación:*

$$q \cdot p = \begin{cases} qp & \text{si } s(q) = t(p), \\ 0 & \text{en otro caso,} \end{cases}$$

y extendida linealmente. Los caminos triviales satisfacen $e_{t(p)}p = p = pe_{s(p)}$ y $e_ie_j = \delta_{ij}e_i$, de modo que $\{e_i\}_{i \in Q_0}$ es un conjunto completo de idempotentes ortogonales y $1 = \sum_i e_i$ es la unidad.

La multiplicación respeta la longitud de los caminos: concatenar un camino de longitud g con uno de longitud h produce un camino de longitud $g + h$ (o cero). Por tanto $\mathbb{k}Q$ es un álgebra graduada,

$$\mathbb{k}Q = \bigoplus_{g \geq 0} \mathbb{k}Q_g, \quad \mathbb{k}Q_g \cdot \mathbb{k}Q_h \subseteq \mathbb{k}Q_{g+h},$$

donde $\mathbb{k}Q_g$ es el subespacio generado por los caminos de longitud exactamente g . En particular $\mathbb{k}Q_0 = \bigoplus_i \mathbb{k}e_i$ y $\mathbb{k}Q_1$ está generado por las flechas.

Los idempotentes e_i nos permiten aislar los caminos entre un par fijo de vértices. Para $i, j \in Q_0$ y $g \geq 0$, el subespacio

$$e_j \cdot \mathbb{k}Q_g \cdot e_i \subseteq \mathbb{k}Q$$

está generado exactamente por los caminos de longitud g de i a j . Su dimensión es por tanto el número de recorridos dirigidos de longitud g de i a j . La siguiente proposición elemental precisa el vínculo con el álgebra lineal y es el sustento computacional del modelo.

Proposition 1 (La multiplicidad graduada es igual al conteo de recorridos). Sea $A \in \mathbb{N}^{n \times n}$ la matriz de adyacencia de Q , $A_{ij} = \#\{\alpha \in Q_1 : \alpha : i \rightarrow j\}$. Entonces para todo $g \geq 0$ y todo $i, j \in Q_0$,

$$\dim_{\mathbb{k}}(e_j \cdot \mathbb{k}Q_g \cdot e_i) = (A^g)_{ij}.$$

Demostración. Por inducción sobre g . Para $g = 0$, $e_j \mathbb{k}Q_0 e_i = \delta_{ij} \mathbb{k}e_i$, de dimensión $\delta_{ij} = (A^0)_{ij} = (\text{Id})_{ij}$. Para $g = 1$, una base de $e_j \mathbb{k}Q_1 e_i$ es el conjunto de flechas $i \rightarrow j$, de cardinalidad A_{ij} . Supongamos la afirmación para $g - 1$. Todo camino de longitud g de i a j se factoriza de manera única como $\alpha \cdot p$, donde p es un camino de longitud $g - 1$ de i a algún vértice intermedio r y $\alpha : r \rightarrow j$ es una flecha. El número de tales factorizaciones es $\sum_r A_{rj} (A^{g-1})_{ir} = (A^g)_{ij}$, lo que prueba la afirmación. $\square$

Llamamos al entero $n_g(i, j) := (A^g)_{ij} = \dim_{\mathbb{k}}(e_j \mathbb{k}Q_g e_i)$ la *multiplicidad de recorrido* de i a j a alcance g . Es exactamente el número de mensajes de longitud g que un GNN de paso de mensajes fuerza a través del nodo j desde el nodo i tras g capas, y por tanto la fuente del over-squashing.

3.3. Un ejemplo explícito

Example 1 (Un quiver diamante). Sea Q con vértices $\{1, 2, 3, 4\}$ y flechas $\alpha_1 : 1 \rightarrow 2$, $\alpha_2 : 1 \rightarrow 3$, $\beta_1 : 2 \rightarrow 4$, $\beta_2 : 3 \rightarrow 4$ (Figura 1). Su matriz de adyacencia y el cuadrado son

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix}, \quad A^2 = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}.$$




Figura 1. El quiver diamante del Ejemplo 1. Los dos recorridos de longitud 2 $1 \rightsquigarrow 4$ son paralelos; $\dim(e_4 \mathbb{k} Q_2 e_1) = 2$.

Hay dos recorridos de longitud 2 de 1 a 4, a saber, $\beta_1 \alpha_1$ y $\beta_2 \alpha_2$, de modo que $\dim(e_4 \mathbb{k} Q_2 e_1) = (A^2)_{14} = 2$, en concordancia con la Proposición 1. Estos dos recorridos son *paralelos*: misma fuente, mismo objetivo, misma longitud. Si deben tratarse como un único canal o como dos es una decisión de modelado a la que volvemos en la Sección 5.

3.4. Operadores de recorrido

La Proposición 1 nos permite convertir el álgebra de caminos graduada en una familia de operadores lineales sobre las características de los nodos, uno por cada alcance g . Estos *operadores de recorrido* son el puente hacia el modelo neuronal.

Definition 4 (Operador de recorrido). Para cada alcance $g \geq 1$ definimos la matriz $W^{(g)} \in \mathbb{R}^{n \times n}$ mediante

$$W_{ji}^{(g)} = \frac{(A^g)_{ij}}{Z_g},$$

donde $Z_g = \max_j \sum_i (A^g)_{ij}$ es una única constante de normalización para el alcance. El soporte de alcanzabilidad por recorrido a alcance g es el conjunto de índices

$$\mathcal{S}_g = \{(j, i) : (A^g)_{ij} > 0\} = \{(j, i) : \dim(e_j \mathbb{k} Q_g e_i) > 0\}.$$

Actuando sobre una matriz de características $H \in \mathbb{R}^{n \times d}$, el operador $W^{(g)} H$ envía a cada nodo j una suma ponderada de las características de cada nodo i que alcanza a j mediante un recorrido de longitud g , siendo el peso proporcional a la multiplicidad de recorrido $n_g(i, j)$. Conviene subrayar dos hechos.

(i) *Normalización global, no normalización por filas.* Dividimos por una única constante Z_g por alcance en lugar de normalizar cada fila para que sume uno. La normalización por filas mapearía las multiplicidades a una distribución uniforme sobre las fuentes alcanzables y borraría la propia información de

multiplicidad que distingue a $W^{(g)}$ de una simple máscara de alcanzabilidad; la constante global mantiene las multiplicidades relativas intactas a la vez que acota la magnitud.

(ii) *Esparcidad*. El soporte $\mathcal{S}_g$ es exactamente el patrón de no nulos de A^g . En los grafos estructurados de interés es una pequeña fracción de todos los n^2 pares (véase la Sección 5), de modo que $W^{(g)}$ puede almacenarse y aplicarse en $O(|\mathcal{S}_g|)$ en lugar de $O(n^2)$.

El operador de pesos fijos $W^{(g)}$ ya mitiga el over-squashing, porque permite que el nodo j lea de las fuentes a alcance g *directamente*, en un solo paso, en lugar de forzar la señal a través de g rondas de paso de mensajes local. Su limitación—que motiva la Walk Attention—es que los pesos están fijados por la multiplicidad y no pueden *seleccionar* qué fuente alcanzable importa. Abordamos esto en la Sección 4 aprendiendo los pesos sobre el mismo soporte.

3.5. El cociente: una relación entre recorridos

La teoría de representaciones pasa habitualmente de $\mathbb{k}Q$ a un cociente $\mathbb{k}Q/I$ por un *ideal admisible* I , identificando caminos que se declaran iguales. En el diamante del Ejemplo 1, la relación $\beta_1\alpha_1 \equiv \beta_2\alpha_2$ genera un ideal I para el cual $\dim(e_4(\mathbb{k}Q/I)_2e_1) = 1$: los dos recorridos paralelos colapsan a una única clase. Más en general, $\dim(e_j(\mathbb{k}Q/I)_ge_i) \leq n_g(i, j)$, de modo que el cociente produce una multiplicidad estructuralmente menor.

Resulta tentador usar este cociente directamente como remedio del over-squashing: reemplazar las multiplicidades de recorrido $n_g(i, j)$ por las dimensiones menores del cociente, “deduplicando” así los caminos redundantes antes de la agregación. Probamos esto y lo encontramos *contraproducente* (Sección 5): colapsar los recorridos paralelos destruye información de multiplicidad que las tareas posteriores pueden requerir. El papel constructivo del cociente, entonces, no es comprimir la señal sino *reconfigurar el soporte*—p. ej. encaminar clases de caminos distintas hacia cabezas de atención distintas—una dirección que dejamos para trabajo futuro. En el modelo que sigue usamos el álgebra de caminos solo a través del soporte de alcanzabilidad $\mathcal{S}_g$ y los operadores de recorrido $W^{(g)}$ (sin cocientar).

4. Atención por Caminos

Definimos ahora la arquitectura. El principio rector es la observación de que el operador de caminos multi-salto de la Sección 3 es estructuralmente una *atención*: agrega, para cada nodo objetivo, una combinación ponderada de las características de los nodos que lo alcanzan. La autoatención del Transformer [10] tiene la misma forma pero con soporte sobre todos los pares y pesos *aprendidos*; la atención sobre grafos [11] restringe el soporte a un salto. La Atención por Caminos conserva los pesos aprendidos de la atención y toma el soporte del álgebra de caminos: la alcanzabilidad por caminos multi-salto y dispersa $\mathcal{S}_g$.

4.1. La capa de Atención por Caminos

Fijemos un rango g con soporte de alcanzabilidad $\mathcal{S}_g$ (Definición 4). Una capa de Atención por Caminos con H cabezas y dimensión de cabeza C transforma las características de los nodos $x \in \mathbb{R}^{n \times d_{\text{in}}}$ del modo siguiente. Para cada cabeza h calcula queries, keys y values mediante aplicaciones lineales,

$$Q^h = x W_Q^h, \quad K^h = x W_K^h, \quad V^h = x W_V^h, \quad W_{\bullet}^h \in \mathbb{R}^{d_{\text{in}} \times C},$$

y luego atiende *sólo sobre los pares alcanzables*: para todo $(j, i) \in \mathcal{S}_g$,

$$\ell_{ji}^h = \frac{1}{\sqrt{C}} \langle Q_j^h, K_i^h \rangle, \quad (1)$$

$$\alpha_{ji}^h = \text{softmax}_{i: (j,i) \in \mathcal{S}_g} (\ell_{ji}^h), \quad (2)$$

$$z_j^h = \sum_{i: (j,i) \in \mathcal{S}_g} \alpha_{ji}^h V_i^h. \quad (3)$$

El softmax en (2) se toma, para cada objetivo j , exactamente sobre las fuentes i que alcanzan a j mediante un camino de longitud g —un softmax *segmentado* sobre el soporte, nunca sobre los n nodos. Las salidas de las cabezas se concatenan (o se promedian en la capa final) y se añade un término “raíz” residual:

$$\text{WA}_g(x)_j = \left\|_{h=1}^H z_j^h + x_j W_{\text{root}}.\right.$$

Como (1)–(3) sólo tocan los pares de $\mathcal{S}_g$, la capa cuesta $O(|\mathcal{S}_g| H C)$ en tiempo y memoria, no $O(n^2)$. El soporte se precuenta una vez por grafo a partir de la Proposición 1 (el patrón de no ceros de A^g). La Figura 2 resume el flujo de datos.

Remark 1 (Por qué importan los pesos aprendidos). El operador de pesos fijos $W^{(g)}$ de la Definición 4 es el caso particular en el que α_{ji}^h se reemplaza por la constante $n_g(i, j)/Z_g$. Alcanza toda fuente de rango g pero las pondera sólo por multiplicidad, de modo que no puede *seleccionar* qué fuente porta la señal relevante. La atención aprendida (1)–(2) restaura esta selectividad mientras conserva el mismo soporte multi-salto. La Sección 5 muestra que esta distinción es decisiva.

4.2. La red

Una red de Atención por Caminos de profundidad L apila una capa por rango $g = 1, \dots, L$. La capa g usa el soporte $\mathcal{S}_g$ derivado de A^g , de modo que las capas sucesivas leen caminos progresivamente más largos. Cada capa va seguida de una normalización de capa, una no linealidad ELU y dropout; un perceptrón multicapa final aplica la incrustación de nodos a las salidas de la tarea:

$$x^{(g)} = \text{dropout}\left(\text{elu}\left(\text{LN}\left(\text{WA}_g(x^{(g-1)}))\right)\right)\right), \quad \hat{y} = \text{MLP}(x^{(L)}).$$




Figura 2. Una capa de Atención por Caminos en el rango g . Las queries, keys y values son aplicaciones lineales de las características de los nodos; la atención se calcula *sólo* sobre los pares alcanzables por caminos $\mathcal{S}_g$ que proporciona el álgebra de caminos (el patrón de no ceros de A^g), y luego se agregan y se suman a un término raíz residual. La caja verde de soporte es lo que distingue a la Atención por Caminos de la atención densa ($\mathcal{S}_g = \text{todos los pares}$) y de un salto ($\mathcal{S}_g = \text{aristas}$).

Algorithm 1 Capa de Atención por Caminos en el rango g (dispersa).

Require: características $x \in \mathbb{R}^{n \times d_{\text{in}}}$; soporte $\mathcal{S}_g = \{(j, i) : (A^g)_{ij} > 0\}$

- 1: $Q, K, V \leftarrow xW_Q, xW_K, xW_V$ ▷ por cabeza; formas $n \times HC$
- 2: **for** each $(j, i) \in \mathcal{S}_g$ and head h **do**
- 3: $\ell_{ji}^h \leftarrow \langle Q_j^h, K_i^h \rangle / \sqrt{C}$
- 4: **end for**
- 5: $\alpha_{ji}^h \leftarrow \text{softmax segmentado sobre } \{i : (j, i) \in \mathcal{S}_g\}$
- 6: $z_j^h \leftarrow \sum_i \alpha_{ji}^h V_i^h$ ▷ scatter-add hacia los objetivos
- 7: **return** $\|_h z^h + xW_{\text{root}}$

La normalización de capa es importante en la práctica: sin ella la atención aprendida tiene alta varianza entre inicializaciones (alcanza el óptimo en algunas semillas y en otras no); con ella, junto con un breve warmup de la tasa de aprendizaje y recorte de gradiente, el entrenamiento converge de forma fiable (Sección 5). El Algoritmo 1 resume una capa.

4.3. Relación con el paso de mensajes y los Transformers

La Tabla 1 sitúa la Atención por Caminos entre los operadores relacionados según dos ejes: el *soporte* de interacción y si los pesos son *aprendidos*. Una capa de atención sobre grafos de un salto [11] aprende pesos pero sólo sobre los vecinos directos, de modo que debe encaminar la señal de largo alcance a través de L capas apiladas—precisamente el régimen donde el over-squashing muerde. Un Transformer de grafo completo [10] aprende pesos sobre todos los pares, pagando $O(n^2)$ y descartando la estructura del grafo a menos que se reinyecte mediante codificaciones posicionales. El operador de caminos de pesos fijos tiene el soporte multi-salto adecuado pero no puede seleccionar. La Atención

Cuadro 1. La Atención por Caminos frente a operadores de agregación relacionados.

Operador	Soporte	Pesos	Costo
GCN / paso de mensajes	1 salto	fijos (grado)	$O(Q_1)$
Atención sobre grafos (GAT)	1 salto	aprendidos	$O(Q_1)$
Operador de caminos $W^{(g)}$	alcanzable por caminos	fijos (multiplicidad)	$O(S_g)$
Transformer de grafo	todos los pares	aprendidos	$O(n^2)$
Atención por Caminos (nuestra) alcanzable por caminos		aprendidos	$O(S_g)$

por Caminos ocupa la celda restante: soporte multi-salto y consciente de la estructura *y* pesos aprendidos y selectivos.

5. Experimentos

Evalúamos Walk Attention sobre una familia controlada de grafos en la que el over-squashing es severo y *ajustable*, de modo que la contribución de cada ingrediente arquitectónico pueda aislarse. Todo el código, las configuraciones y un registro completo de seguimiento de experimentos se publican junto con el artículo.

5.1. Un benchmark de over-squashing ajustable

Grafos de cadena con cuello de botella. Construimos una familia parametrizada por una *profundidad* d , un número de fuentes K y un ancho M . El grafo tiene K vértices fuente, luego d *capas de cuello de botella* consecutivas de M vértices intercambiables cada una, y finalmente un vértice objetivo. Cada fuente se conecta con cada vértice de la primera capa, cada vértice de la capa r se conecta con cada vértice de la capa $r + 1$, y cada vértice de la última capa se conecta con el objetivo. Como los vértices del cuello de botella son intercambiables, el número de caminos de longitud $(d+1)$ desde una fuente hasta el objetivo es M^d , así que la multiplicidad de caminos hacia el objetivo crece como $n_{d+1}(\cdot, \text{target}) \sim K M^d$ (Proposición 1); una GNN de paso de mensajes debe comprimirlos todos en el vector de ancho fijo del objetivo. El soporte de alcanzabilidad por caminos, en cambio, permanece disperso: en el rango más profundo es solo el de los K pares fuente–objetivo, aproximadamente el 2% de todos los pares de nodos en nuestra configuración.

Tarea. Cada fuente lleva una *clave* one-hot y una *carga útil* escalar; el objetivo lleva una clave de consulta. El modelo debe producir, en el nodo objetivo, la clave de la fuente cuya clave coincide con la consulta—una tarea de recuperación cuya respuesta se sitúa a $d+1$ saltos de distancia, detrás del cuello de botella. La precisión se mide en el nodo objetivo; el azar es $1/K$.

Cuadro 2. Precisión en el objetivo (media $\pm$ desv. estándar sobre 5 semillas) en la recuperación en cadena con cuello de botella, $K=5$, $M=4$. El azar es $1/K = 0,20$. La profundidad d es el número de capas de cuello de botella; la respuesta se sitúa a $d+1$ saltos de distancia.

Model	depth $d = 2$	depth $d = 3$
GAT (one-hop attention)	$0,44 \pm 0,12$	$0,26 \pm 0,10$
Walk operator (fixed weights)	$0,62 \pm 0,12$	$0,50 \pm 0,12$
Walk Attention (ours)	$1,000 \pm 0,000$	$1,000 \pm 0,000$

Modelos. Comparamos:

- **GAT** [11]: atención de grafos de un salto, $d+1$ capas (pesos aprendidos, soporte de un salto);
- **Operador de caminos (walkraw)**: el operador multi-salto de pesos fijos $W^{(g)}$ de la Definición 4 (soporte multi-salto, pesos fijos de multiplicidad);
- **Walk Attention** (nuestro): Algoritmo 1 (soporte multi-salto, pesos aprendidos).

Todos los modelos usan ancho oculto 16, cuatro cabezas cuando corresponde, y $d+1$ capas/rangos. Entrenamos con AdamW, un warmup lineal de la tasa de aprendizaje de diez épocas seguido de decaimiento coseno, y recorte de gradiente; Walk Attention usa además normalización de capa después de cada capa. Reportamos la media y la desviación estándar de la precisión en el objetivo sobre cinco semillas aleatorias, en las profundidades de problema $d \in \{2, 3\}$ con $K = 5$, $M = 4$.

5.2. Resultado principal

La Tabla 2 reporta los resultados. La GAT de un salto colapsa hacia el azar (0,26–0,44): no puede transportar la señal a través del cuello de botella, como es de esperar de un operador local bajo over-squashing. El operador de caminos de pesos fijos alcanza el objetivo—su soporte multi-salto sorteas el cuello de botella—pero, al ponderar todas las fuentes alcanzables únicamente por multiplicidad, no puede seleccionar la fuente que coincide y se estanca en 0,50–0,62. **Walk Attention resuelve la tarea exactamente**, alcanzando una precisión de $1,000 \pm 0,000$ en ambas profundidades y en las cinco semillas: el mismo soporte multi-salto, ahora con pesos consulta-clave aprendidos, permite que el objetivo atienda selectivamente a la fuente relevante.

Sobre la estabilidad. Sin normalización de capa ni warmup, Walk Attention tiene un techo alto pero es de alta varianza: a través de las semillas su precisión osciló entre 0,44 y 1,00. Los tres estabilizadores estándar (normalización de capa, warmup de la tasa de aprendizaje, recorte de gradiente) eliminan por completo esta varianza, dando como resultado el $\pm 0,000$ de la Tabla 2. La inestabilidad fue, por tanto, un artefacto de optimización, no una propiedad del operador.

Cuadro 3. Precisión de RINGTRANSFER frente al tamaño del anillo n (distancia $n/2$); azar = 0,20. GCN/GAT de un salto colapsan a medida que el anillo—y por tanto el over-squashing—crece, mientras que Walk Attention se mantiene exacto.

Model	$n=6$	$n=10$	$n=14$	$n=18$
GCN	1,00	1,00	0,25	0,59
GAT	1,00	1,00	0,43	0,60
Walk Attention (ours)	1,00	1,00	1,00	1,00

5.3. Una prueba estándar con caminos paralelos claros: RingTransfer

La familia de cuellos de botella es construcción propia. Para confirmar el efecto en un benchmark *independiente* usamos RINGTRANSFER [3]: un ciclo de n nodos donde una fuente debe transmitir su etiqueta one-hot al objetivo diametralmente opuesto. Los caminos paralelos son inconfundibles—la información puede recorrer los *dos arcos* del anillo, dos caminos de igual longitud $n/2$ —y el over-squashing es severo y ajustable, pues el número de caminos de longitud $n/2$ hacia el objetivo crece como $4^{n/2}$ con el tamaño del anillo. La tarea necesita $n/2$ saltos, luego un modelo de un salto necesita $n/2$ capas. Usamos cinco clases (azar 0,2), el mismo ancho y receta de entrenamiento, y $n/2$ capas/rangos para todos los modelos.

La Tabla 3 muestra el panorama esperado. En anillos pequeños ($n \leq 10$) todos los modelos tienen éxito—la compresión aún no es severa. Desde $n = 14$ (distancia 7), las líneas base de un salto colapsan—GCN y GAT caen a 0,25–0,60—mientras que **Walk Attention se mantiene en 1,000**: su soporte multi-salto deja que el objetivo lea la fuente directamente por cualquier arco, y los pesos aprendidos identifican la fuente etiquetada. La separación crece con el tamaño del anillo, es decir, con la severidad del over-squashing.

5.4. Un resultado negativo: colapsar caminos perjudica

El cociente del álgebra de caminos $\mathbb{k}Q/I$ de la Sección 3 sugiere un remedio alternativo: reemplazar las multiplicidades de caminos $n_g(i, j)$ por las dimensiones del cociente $\dim(e_j(\mathbb{k}Q/I)_g e_i)$, más pequeñas, deduplicando caminos equivalentes antes de la agregación. Implementamos esto (el operador de pesos fijos construido a partir de las dimensiones del cociente) y lo comparamos con el operador de caminos sin cociente sobre la misma tarea, en una ablación controlada separada que cambia *únicamente* el operador (cociente frente a crudo) y mantiene todo lo demás fijo. Como muestra la Tabla 4, **el operador del cociente rinde peor que el crudo**: colapsar caminos paralelos descarta la multiplicidad de fuentes que la tarea de recuperación necesita. En este régimen los caminos redundantes son *señal*, no ruido, y eliminarlos elimina información.

Este resultado negativo es informativo: nos dice que el valor del álgebra de caminos aquí *no* es la compresión. El uso correcto del álgebra es proporcionar

Cuadro 4. Deduplicar caminos vía el cociente $\mathbb{k}Q/I$ *perjudica*: precisión en el objetivo (media sobre 3 semillas), recuperación con cuello de botella. Esta es una ablación separada (3 semillas, sin los estabilizadores de la Tabla 2) que aísla el cambio de operador, así que la columna del operador de caminos no es directamente comparable con la Tabla 2; lo que importa aquí es la brecha dentro de cada fila: el operador del cociente está consistentemente por debajo del operador sin cociente.

Operator	depth $d = 2$	depth $d = 3$
Quotient $\mathbb{k}Q/I$ (collapsed walks)	0,47	0,52
Walk operator (raw walks)	0,64	0,53

el *soporte* de la atención multi-salto (lo cual hace, de forma dispersa y exacta), y dejar que la red aprenda pesos sobre ese soporte—que es precisamente Walk Attention. Consideramos que encontrar un régimen en el que la compresión del cociente sea en sí misma beneficiosa (p. ej. cuando los caminos paralelos son genuinamente ruido redundante, o cuando clases de caminos distintas deban enrutarse hacia cabezas distintas) es una cuestión abierta más que un resultado negativo zanjado.

5.5. Un benchmark real de largo alcance: LRGB Peptides-func

El benchmark sintético es deliberadamente un peor caso: un cuello de botella extremo donde el alcance multi-salto es decisivo. Para ver cómo se comporta Walk Attention con datos reales evaluamos también en **Peptides-func** del Long Range Graph Benchmark [4] (10,873/2,331/2,331 grafos moleculares de entrenamiento/validación/prueba, mediana 138 nodos; clasificación multietiqueta de grafos, métrica Average Precision). Usamos el mismo embedding de átomos, cuatro capas, ancho oculto 80, pooling de media y AdamW para todos los modelos; Walk Attention usa los rangos $g = 1, \dots, 4$ con el soporte de alcanzabilidad por caminos de cada molécula. En estos grafos el soporte permanece disperso (1–8 % de n^2 en el rango 3), de modo que el método sigue siendo barato.

En AP de prueba obtenemos GCN 0,484, GAT **0,527** y Walk Attention 0,522. **Walk Attention es competitivo con las líneas base fuertes pero no las supera aquí:** claramente supera a GCN y es estadísticamente indistinguible de GAT. Lo reportamos con franqueza. *No* es por falta de caminos paralelos: los grafos de péptidos sí contienen anillos y ramificaciones, y una molécula típica tiene cientos de pares de vértices unidos por ≥ 2 caminos de longitud ≤ 4 (que el ideal del cociente colapsaría). La razón es que el over-squashing es *leve*: estos grafos son pequeños (mediana 138 nodos), así que unas pocas capas de atención de un salto ya alcanzan suficientemente lejos, y la multiplicidad hacia cualquier nodo nunca crece lo bastante como para saturar el embedding. El soporte multi-salto, decisivo bajo over-squashing severo, aporta poco cuando la compresión es leve. La ventaja de Walk Attention es por tanto *dependiente del régimen*—grande cuando la compresión es severa (Tablas 2 y 3) y un empate cuando es

leve—y, con datos reales, el operador aún entrena de forma estable y barata; no se degrada.

5.6. Costo

Walk Attention opera sobre el soporte de alcanzabilidad por caminos, de tamaño el número de entradas no nulas de A^g : una pequeña fracción de n^2 ($\sim 2\%$ en el rango más profundo), por lo que la capa es mucho más barata que un Transformer de grafos denso conservando su largo alcance. Los soportes se precaculan una vez por topología y se almacenan en caché, así que el cálculo del álgebra no entra en el bucle de entrenamiento.

6. Conclusión y Trabajo Futuro

Introducimos **Walk Attention**, una arquitectura que mitiga el over-squashing en redes neuronales de grafos atendiendo sobre un soporte multi-salto proporcionado por el álgebra de caminos del quiver subyacente. El álgebra de caminos graduada da, a través de la Proposición 1, una descripción exacta de qué pares de nodos están conectados por caminos de longitud- g y con qué multiplicidad; usamos esto para definir una atención dispersa cuyo soporte está determinado algebraicamente y cuyos pesos son aprendidos. Sobre un benchmark de cuello de botella ajustable, Walk Attention resolvió exactamente una tarea de recuperación de largo alcance ($1,000 \pm 0,000$ sobre cinco semillas) donde una red de atención de un salto colapsó al azar y un agregador multi-salto de pesos fijos solo tuvo éxito parcialmente; sobre el benchmark real Peptides-func fue competitivo con líneas base fuertes mientras permanecía disperso y estable. Su ventaja depende del régimen—decisiva cuando el over-squashing es severo y un empate cuando es leve—lo cual reportamos llanamente en lugar de sobreafirmar. Un resultado negativo complementario mostró que usar el *cociente* del álgebra de caminos para comprimir caminos equivalentes es contraproducente cuando la multiplicidad de caminos porta señal; el valor del álgebra es dar forma al soporte de la atención, no descartar información.

La construcción es deliberadamente elemental y autocontenida, de modo que pueda servir como punto de entrada que conecte la teoría de representaciones de quivers con el aprendizaje de representaciones de grafos. Varias direcciones se siguen naturalmente.

- **Benchmarks con over-squashing severo.** Peptides-func es un caso leve donde el soporte multi-salto no es decisivo. El paso siguiente natural es identificar tareas reales de largo alcance cuyos grafos sí tengan cuellos de botella agudos—donde la ventaja sintética debería transferirse—y comparar contra rewiring [9] y graph Transformers.
- **Soportes con forma de cociente.** El cociente $\mathbb{k}Q/I$, en lugar de comprimir la señal, puede *particionar* los caminos en clases de equivalencia; enrutar clases distintas a cabezas distintas dejaría que el álgebra estructure las cabezas. Aprender qué relaciones I son útiles es un problema atractivo.

- **Escalar el soporte.** Para grafos densos el soporte de rango- g puede crecer; truncar, muestrear o aprender un soporte admisible más disperso controlan el costo preservando el largo alcance.

Reproducibilidad. Todos los generadores de grafos, los operadores de walk, la capa Walk Attention, las líneas base y los registros de experimentos están liberados. Los cálculos del álgebra se apoyan en una biblioteca abierta de quivers/álgebras de caminos; este trabajo es, hasta donde sabemos, la primera aplicación publicada de esa maquinaria algebraica a redes neuronales de grafos, por lo que mantuvimos la construcción algebraica explícita en todo momento.

Referencias

1. Alon, U., Yahav, E.: On the bottleneck of graph neural networks and its practical implications. In: International Conference on Learning Representations (ICLR) (2021)
2. Assem, I., Simson, D., Skowroński, A.: Elements of the Representation Theory of Associative Algebras: Volume 1. Cambridge University Press (2006)
3. Di Giovanni, F., Giusti, L., Barbero, F., Luise, G., Lio, P., Bronstein, M.M.: On over-squashing in message passing neural networks: The impact of width, depth, and topology. In: Proceedings of the 40th International Conference on Machine Learning (ICML). PMLR, vol. 202, pp. 7865–7885 (2023)
4. Dwivedi, V.P., Rampášek, L., Galkin, M., Parviz, A., Wolf, G., Luu, A.T., Beaini, D.: Long range graph benchmark. In: Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track. vol. 35 (2022)
5. Gilmer, J., Schoenholz, S.S., Riley, P.F., Vinyals, O., Dahl, G.E.: Neural message passing for quantum chemistry. In: Proceedings of the 34th International Conference on Machine Learning (ICML). PMLR, vol. 70, pp. 1263–1272 (2017)
6. Moreno Cañadas, A., Rodríguez-Nieto, J.G., Salazar Díaz, O.P.: Brauer configuration algebras induced by integer partitions and their applications in the theory of branched coverings. *Mathematics* **12**(22), 3626 (2024). <https://doi.org/10.3390/math12223626>
7. Osorio Angarita, M.A., Moreno Cañadas, A.: Brauer configuration algebras for multimedia based cryptography and security applications. *Multimedia Tools and Applications* **80**(15), 23485–23510 (2021). <https://doi.org/10.1007/s11042-020-10239-3>
8. Schiffler, R.: Quiver Representations. Springer (2014)
9. Topping, J., Di Giovanni, F., Chamberlain, B.P., Dong, X., Bronstein, M.M.: Understanding over-squashing and bottlenecks on graphs via curvature. In: International Conference on Learning Representations (ICLR) (2022)
10. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. In: Advances in Neural Information Processing Systems (NeurIPS). vol. 30 (2017)
11. Veličković, P., Cucurull, G., Casanova, A., Romero, A., Lio, P., Bengio, Y.: Graph attention networks. arXiv preprint arXiv:1710.10903 (2017)